

MÓDULO 2 (Exclusivo para Sênior)

Considere as duas tabelas:

- ☐ Tabela usuarios: id_usuario (inteiro), nome (texto), data_cadastro (data)
- ☐ Tabela acessos: id_acesso (inteiro), id_usuario (inteiro), data_acesso (data), servico_acessado (texto)

4. A área de produto quer entender a recorrência de uso dos serviços. **Usando as mesmas tabelas da Questão 2, escreva uma consulta SQL que retorne:**

- ☐ O nome do usuário.
- ☐ A data_acesso.
- ☐ O servico_acessado.
- ☐ Uma nova coluna chamada dias_desde_ultimo_acesso, calculada com a diferença (em dias) entre o acesso atual e o anterior do mesmo usuário

Obrigatório:

- ☐ usar funções de janela (Window Functions)
- ☐ usar LAG()
- ☐ o primeiro acesso do usuário deve retornar NULL nessa coluna

```
SELECT
u.nome,
a.data_acesso,
a.servico_acessado,
DATE_PART('day', a.data_acesso - LAG(a.data_acesso) OVER (
PARTITION BY a.id_usuario
ORDER BY a.data_acesso
)) AS dias_desde_ultimo_acesso
FROM
acessos a
JOIN
usuarios u ON a.id_usuario = u.id_usuario
ORDER BY
u.nome, a.data_acesso;
```

Você recebeu um DataFrame com:

- regiao (categórica)
- tipo_servico (categórica)
- tempo_resposta (numérica)
- avaliacao_cliente (1 a 5)

Seu objetivo é preparar esses dados para um modelo de Machine Learning que prevê se a avaliação será Boa (1) ou Ruim (0). Responda:

1. Como você criaria a variável-alvo (target) “satisfacao”?
2. Qual a diferença entre StandardScaler e One-Hot Encoding?
3. Em quais colunas aplicaria cada técnica e por quê?

Responder apenas com texto. Não enviar código.

1)

Transformamos a coluna “avaliação do cliente”, onde "Satisfação" Bom(1) pega as avaliações 4-5 – momentos esses em que queremos multiplicar para potencializar ganhos - enquanto "Insatisfação" Ruim(0) sinaliza as avaliações 1-3, revelando oportunidades para minimizar riscos e rever estratégias .

Esta clareza transforma dados complexos em insights acionáveis para focar nossos esforços nas métricas crucialmente importantes, geralmente na redução de riscos como um todo e maximizando lucros.

2)

Usamos **StandardScaler** para variáveis numéricas contínuas (ex: tempo_resposta), baseado na média e desvio padrão, ideal para quando os dados seguem uma distribuição normal. Preserva a distribuição original, apenas ajusta escala.

Já para **One-Hot Encoding** para variáveis categóricas nominais (ex: região e tipo_servico), cria colunas binárias (0/1) para cada categoria, expandindo dimensionalmente, permite que algoritmos matemáticos processem categorias sem atribuir ordem, transforma completamente a estrutura, criando "variáveis fantasmas". Enquanto o **StandardScaler** padroniza números, o **One-Hot Encoding** traduz categorias para a linguagem dos algoritmos de Machine Learning.

3)

Na jornada de preparação dos dados, aplicamos as técnicas nas seguintes situações: o **StandardScaler** harmoniza métricas numéricas como a coluna “tempo de resposta” justificativa como citado parágrafo anterior, enquanto o **One-Hot Encoding** traduz as colunas região e tipos de serviço em linguagem compreensível para o algoritmo, revelando padrões ocultos de desempenho.

MÓDULO 1 (Obrigatório para Todos)

1. Você recebeu uma planilha com atendimentos realizados pela CAIXA contendo:

- ☐ data_atendimento
- ☐ regioao
- ☐ tipo_servico
- ☐ tempo_resposta (minutos)
- ☐ avaliacao_cliente (1 a 5)

A área de atendimento ao cliente quer entender como está o desempenho dos serviços em cada região, com foco na melhoria da experiência do cidadão. Com base nesse cenário, responda:

- ☐ Quais indicadores simples você poderia calcular para ajudar a área a entender o desempenho por região?
- ☐ Como você identificaria se há regiões com desempenho abaixo da média?
- ☐ Que tipo de gráfico você recomendaria para apresentar esses dados de forma clara à gestão?

Quais indicadores simples você poderia calcular para ajudar a área a entender o desempenho por região?

Indicadores relacionados à **eficiência**, **satisfação** e **demanda**:

Em eficiência, o **tempo médio** de resposta e sua **evolução mensal**, permitindo verificar agilidade e tendências de melhora, estabilidade ou piora no desempenho ao longo do tempo.

Em satisfação, a **avaliação média** dos clientes, que representa diretamente a percepção do cidadão sobre a qualidade do atendimento, e o **percentual de avaliações negativas** (notas 1 e 2), importante para identificar regiões com maior risco de insatisfação e necessidade de intervenção.

Já em demanda, a **quantidade total** de atendimentos para entender o volume operacional de cada região e o **percentual por tipo de serviço**, permitindo identificar quais serviços concentram maior demanda e apoiando decisões operacionais e de alocação de recursos.

Como você identificaria se há regiões com desempenho abaixo da média?

EFICIÊNCIA, regiões com tempo médio de resposta **acima da média global**, atendimento mais lento.
SATISFAÇÃO: regiões com avaliações média de clientes **abaixo da média global**, percepção negativa.
DEMANDA, regiões com média de atendimentos **acima da média global**, sobrecarga, filas e queda na qualidade.

Conclusão: O desempenho das regiões "abaixo da média" é caracterizado por qualquer desvio negativo em relação a esses indicadores globais, destacando pontos críticos que exigem atenção imediata para melhorar a experiência do cidadão.

Que tipo de gráfico você recomendaria para apresentar esses dados de forma clara à gestão?

Gráficos de colunas verticais com linha de referência da média global para comparar o desempenho entre regiões.

Gráficos de barras horizontais empilhadas para visualizar a distribuição dos atendimentos por tipo de serviço em cada região.

Gráfico de linhas com o tempo médio de resposta mensal por região, permitindo acompanhar a evolução ao longo do tempo.

Para uma visão integrada, utilizaria um gráfico de bolhas (Scatter Plot) relacionando tempo médio de resposta, avaliação média e volume de atendimentos, permitindo identificar rapidamente regiões críticas com maior impacto na experiência do cliente, como aquelas com alto tempo de resposta e baixa avaliação.

Além do scatter plot com três dimensões, posso adicionar uma quarta dimensão temporal utilizando animação (Play Axis), permitindo analisar a evolução dos indicadores ao longo do tempo.

Questão 2

Considere as duas tabelas:

- Tabela usuarios: id_usuario (inteiro), nome (texto), data_cadastro (data)
- Tabela acessos: id_acesso (inteiro), id_usuario (inteiro), data_acesso (data), servico_acessado (texto)

Escreva uma consulta SQL que retorne:

- O nome do usuário.
- A quantidade de acessos realizados no último mês.
- Apenas os usuários que realizaram mais de 5 acessos nesse período.

Obrigatório: utilizar corretamente o período do mês anterior fechado, não “últimos 30 dias”.

```
SELECT
u.nome,
COUNT(a.id_acesso) AS quantidade_acessos
FROM
usuarios u
JOIN
acessos a ON u.id_usuario = a.id_usuario
WHERE
a.data_acesso >= DATE_TRUNC('month', CURRENT_DATE - INTERVAL '1
month')
AND a.data_acesso < DATE_TRUNC('month', CURRENT_DATE)
GROUP BY
u.nome
HAVING
COUNT(a.id_acesso) > 5
ORDER BY
quantidade_acessos DESC;
```

3. Você recebeu dois arquivos .csv: atendimentos.csv e clientes.csv.

□ **atendimentos.csv:** id_atendimento, data_atendimento, id_cliente, tipo_servico, tempo_resposta (com alguns valores nulos)

□ **clientes.csv:** id_cliente, regioao, data_cadastro

Usando a biblioteca Pandas, escreva o script Python completo que realize as seguintes etapas:

1. Carregue os dois arquivos.
2. Faça um merge trazendo “regiao” para a base de atendimentos.
3. Conte e exiba a quantidade de valores nulos em tempo_resposta.
4. Preencha os valores nulos com a média GLOBAL de tempo_resposta (não usar média por grupo).
5. Calcule e exiba o tempo médio de resposta por região, ordenando do menor para o maior.

```
import pandas as pd
```

```
# Carregar os arquivos CSV
```

```
atendimentos = pd.read_csv('atendimentos.csv')
```

```
clientes = pd.read_csv('clientes.csv')
```

```
# Merge para trazer a coluna 'regiao' para a base de atendimentos
```

```
atendimentos = atendimentos.merge(clientes[['id_cliente', 'regiao']], on='id_cliente',  
how='left')
```

```
# Contar e exibir a quantidade de valores nulos em 'tempo_resposta'
```

```
nulos = atendimentos['tempo_resposta'].isnull().sum()
```

```
print(f"Quantidade de valores nulos em tempo_resposta: {nulos}")
```

```
# Calcular a média global de tempo_resposta (ignorando nulos)
```

```
media_global = atendimentos['tempo_resposta'].mean()
```

```
# Preencher os valores nulos com a média global
```

```
atendimentos['tempo_resposta'].fillna(media_global, inplace=True)
```

```
# Calcular o tempo médio de resposta por região, ordenando do menor para o maior
```

```
media_por_regiao =
```

```
atendimentos.groupby('regiao')['tempo_resposta'].mean().sort_values()
```

```
print("Tempo médio de resposta por região (do menor para o maior):")
```

```
print(media_por_regiao)
```