

Gabarito Comentado

Processo Seletivo — Analista de Dados Jr / Pleno

BLOCO 1 — MÚLTIPLA ESCOLHA

QUESTÃO 1 — Valores nulos na coluna renda_mensal

Você recebeu uma base com 500 mil registros. A coluna renda_mensal possui 12% de valores nulos. Antes de decidir como tratar, você precisa entender se a ausência é aleatória ou concentrada em algum segmento. **Qual abordagem é a mais adequada como primeiro passo?**

☐ Excluir todos os registros com renda nula para garantir uma base limpa.

☒ **Investigar o padrão dos nulos (segmento, canal, região) para entender se a ausência é aleatória ou indica viés sistemático.**

☐ Preencher todos os valores nulos com a média geral da coluna renda_mensal.

☐ Substituir os valores por zero para manter todos os registros.

Explicação: Dados ausentes podem ser MCAR (aleatório), MAR (relacionado a outras variáveis) ou MNAR (relacionado ao próprio valor). O primeiro passo é sempre diagnosticar o tipo antes de decidir o tratamento. Excluir 60 mil registros sem entender o padrão pode introduzir viés grave na análise.

QUESTÃO 2 — Práticas obrigatórias para pipeline de dados

Você está projetando um pipeline que alimentará dashboards executivos e modelos analíticos com dados de 5 fontes diferentes. **Selecione TODAS as práticas obrigatórias:**

☒ **Validação automática de qualidade em cada etapa (tipos, ranges, nulos, duplicatas) com alertas.**

☐ Processamento manual em planilhas para garantir controle total.

☒ **Registro de data lineage para rastrear origem e transformações.**

☒ **Versionamento das regras de transformação com documentação das alterações.**

Explicação: Pipeline robusto = automação + rastreabilidade + reprodutibilidade. Processamento manual em planilhas não escala, não é auditável e é fonte de erro humano — incompatível com 5 fontes e frequências distintas de atualização.

QUESTÃO 3 — Gráfico para evolução mensal de receita (24 meses)

Você precisa apresentar a evolução mensal da receita ao longo de 24 meses para a diretoria, destacando tendência geral e possíveis sazonalidades. **Qual tipo de gráfico é o mais adequado?**

☐ Gráfico de pizza com uma fatia para cada mês.

☒ **Gráfico de linhas com eixo X representando os meses e eixo Y a receita.**

☐ Gráfico de barras empilhadas com uma barra por mês.

☐ Tabela com todos os valores numéricos organizados por mês.

Explicação: Gráfico de linha é ideal para séries temporais. Com 24 pontos no eixo X, a linha evidencia tendência e sazonalidade naturalmente. O próprio enunciado entrega a resposta: 'destacando tendência e sazonalidades' são exatamente o que linha mostra melhor.

QUESTÃO 4 — Eixo Y truncado no gráfico de barras

Um gráfico de barras compara satisfação entre 3 canais (escala 0 a 10). As barras iniciam em 7,0: Canal A = 7,2; Canal B = 7,8; Canal C = 7,5. A diferença visual parece significativa. **Qual o principal problema desse gráfico?**

✗ Não há problema — o truncamento ajuda a perceber diferenças sutis.

✓ **O eixo Y truncado (iniciando em 7,0) amplifica visualmente diferenças de 0,6 ponto, podendo induzir interpretações equivocadas.**

✗ O problema está na escolha de barras — linhas seriam mais adequadas.

✗ O gráfico deveria ser substituído por tabela numérica.

Explicação: Numa escala de 0 a 10, diferença de 0,6 ponto é pequena. Com eixo iniciando em 7,0, a barra menor parece ter metade do tamanho da maior — distorcendo completamente a percepção. A correção é iniciar o eixo Y em 0.

QUESTÃO 5 — Medida de tendência central em distribuição assimétrica

A distribuição dos valores de transações dos clientes é fortemente assimétrica à direita, com poucos clientes concentrando volumes muito elevados. **Qual medida de tendência central é a mais representativa para reportar ao gestor?**

✗ Média aritmética, pois é a medida mais utilizada.

✓ **Mediana, pois não é afetada por valores extremos e representa melhor o comportamento típico.**

✗ Moda, pois o valor mais frequente é mais intuitivo.

✗ Desvio padrão, pois descreve a dispersão dos dados.

Explicação: Em distribuição assimétrica à direita, poucos outliers de alto valor puxam a média para cima, fazendo ela não representar a maioria dos clientes. A mediana divide a distribuição ao meio — não é influenciada por extremos. Regra: assimétrica = mediana.

QUESTÃO 6 — Correlação de Pearson e causalidade (churn)

Correlação de Pearson de -0,78 entre número de interações com suporte e tempo de permanência do cliente. A área de negócio conclui: 'clientes que ligam mais saem mais rápido, então devemos reduzir o acesso ao suporte'. **Qual análise está correta?**

✗ A conclusão está correta — correlação de -0,78 confirma que o suporte causa a saída.

✓ **Correlação não implica causalidade. Clientes insatisfeitos buscam mais suporte antes de cancelar — a insatisfação é a causa provável de ambos.**

✗ Correlação de -0,78 é fraca demais — apenas valores acima de 0,90 são significativos.

✗ Pearson não se aplica pois mede apenas relações entre variáveis categóricas.

Explicação: -0,78 é correlação forte (não existe limiar universal de 0,90 — isso é mito). Mas correlação $\neq$ causalidade. A insatisfação do cliente é variável de confusão: causa tanto mais ligações ao suporte quanto o cancelamento. Reduzir acesso ao suporte pioraria a experiência e aceleraria o churn.

QUESTÃO 7 — Validação estatística de hipótese (ticket médio por canal)

A diretoria acredita que clientes do canal digital têm ticket médio maior que os do presencial. Você precisa validar com rigor estatístico. **Selecione TODAS as práticas adequadas:**

✓ **Formular hipótese nula (médias iguais) e alternativa (digital > presencial), escolhendo teste adequado.**

✗ Comparar apenas as médias e reportar qual é maior — diferença observada já é suficiente.

✓ **Verificar premissas do teste (normalidade, homocedasticidade) e selecionar alternativa não paramétrica se necessário.**

✓ **Reportar resultado com intervalo de confiança, tamanho do efeito e representatividade da amostra.**

Explicação: Diferença observada nas médias pode ser acaso amostral. Sem teste estatístico não há validade. P-valor sozinho também não basta — resultado pode ser significativo mas com efeito pequeno. IC + tamanho do efeito completam o rigor.

QUESTÃO 8 — Dashboard executivo de KPIs de crédito

Você vai construir um dashboard executivo para acompanhar KPIs de operações de crédito, usado pela diretoria para tomada de decisão semanal. **Selecione TODAS as práticas que devem guiar o projeto:**

✓ **Definir KPIs a partir das decisões que o dashboard deve apoiar, priorizando métricas acionáveis.**

✗ Incluir o máximo de métricas possível para cobrir todos os cenários.

✓ **Documentar a lógica de cálculo e automatizar a atualização com alertas em caso de falha.**

✓ **Validar o protótipo com usuários finais antes da entrega, iterando sobre hierarquia visual.**

Explicação: Dashboard executivo = menos é mais. Excesso de métricas paralisa a decisão. Cada KPI deve responder uma pergunta de negócio específica. Documentação garante que dois analistas calculem a mesma métrica da mesma forma.

QUESTÃO 9 — Como abordar demanda vaga do gestor

O gestor solicita: 'Preciso de um relatório com todos os dados de vendas do último ano'. A demanda é ampla. **Qual é a melhor forma de abordar?**

✗ Extrair imediatamente todos os dados e enviar planilha completa.

✓ **Agendar uma conversa para entender o objetivo, quais decisões serão tomadas e quais recortes são prioritários.**

✗ Informar que a demanda é genérica e solicitar que o gestor reescreva com especificações técnicas.

✗ Criar dashboard com todas as métricas de vendas disponíveis.

Explicação: Demanda vaga é ponto de partida, não problema. O analista faz as perguntas certas para transformar 'quero dados de vendas' em 'preciso da taxa de conversão por canal nos últimos 3 meses'. Pedir especificações técnicas ao gestor transfere responsabilidade para quem não tem obrigação de saber SQL.

QUESTÃO 10 — Comunicar achado que contradiz crença da gerência

Sua análise mostra que uma campanha considerada bem-sucedida (aumento de 30% em contratações) gerou prejuízo líquido: inadimplência 3x maior e ticket médio 40% menor. **Como comunicaria esses achados?**

✗ Apresentar apenas o dado positivo para não gerar conflito.

✗ Enviar e-mail direto ao diretor mostrando que a campanha foi um fracasso.

✓ **Reconhecer o resultado de volume, apresentar os dados de qualidade com evidências e propor ajustes na segmentação para a próxima campanha.**

✗ Aguardar que a gerência perceba o problema com o tempo.

Explicação: A resposta correta equilibra honestidade, respeito ao contexto político e orientação para o futuro. Omitir dados é antiético. Bypassar a gerência diretamente ao diretor queima relacionamento. Aguardar é negligência. Reconhecer + evidenciar + propor é a postura do analista pleno.

QUESTÃO 11 — Descoberta não solicitada com alto impacto

Ao analisar dados rotineiros, você identifica que clientes com dois produtos específicos têm retenção 45% maior e inadimplência 60% menor. Nenhuma área solicitou essa análise. **Selecione TODAS as ações adequadas:**

✓ **Validar a robustez do achado: tamanho amostral, variáveis de confusão, diferentes períodos.**

✗ Apresentar imediatamente à diretoria como descoberta confirmada para ganhar visibilidade.

✓ **Estruturar o achado como oportunidade de negócio: estimar impacto e propor piloto de cross-sell.**

✓ **Comunicar ao gestor com linguagem de negócio, destacando impacto financeiro e próximos passos.**

Explicação: Sequência correta — validar (o achado é real?) → estruturar (qual o impacto?) → comunicar (como gerar ação?). Apresentar como 'confirmado' antes de validar é desonesto. A motivação 'antes que outro encontre' é vaidade, não rigor.

BLOCO 2 — SQL

QUESTÃO 12 — Perfil transacional por cliente

A área de negócio solicitou uma visão consolidada por cliente a partir da tabela transacoes (colunas: id, cpf_cliente, valor, tipo [CREDITO/DEBITO], data_transacao, canal, status). Retorne: cpf_cliente, total_transacoes_efetivadas, valor_total_credito, valor_total_debito, saldo_liquido, canal_mais_frequente, data_ultima_transacao. Filtro: status = 'EFETIVADA'. Ordenar por valor_total_credito DESC.

Nível Júnior:

```
SELECT cpf_cliente, COUNT(id) AS total_transacoes_efetivadas, SUM(CASE WHEN tipo = 'CREDITO' THEN valor ELSE 0 END) AS valor_total_credito, SUM(CASE WHEN tipo = 'DEBITO' THEN valor ELSE 0 END) AS valor_total_debito, SUM(CASE WHEN tipo = 'CREDITO' THEN valor WHEN tipo = 'DEBITO' THEN -valor ELSE 0 END) AS saldo_liquido, MAX(data_transacao) AS data_ultima_transacao FROM transacoes WHERE status = 'EFETIVADA' GROUP BY cpf_cliente ORDER BY valor_total_credito DESC
```

Nível Pleno (com canal_mais_frequente via subquery):

```
SELECT cpf_cliente, COUNT(id) AS total_transacoes_efetivadas, SUM(CASE WHEN tipo = 'CREDITO' THEN valor ELSE 0 END) AS valor_total_credito, SUM(CASE WHEN tipo = 'DEBITO' THEN valor ELSE 0 END) AS valor_total_debito, SUM(CASE WHEN tipo = 'CREDITO' THEN valor WHEN tipo = 'DEBITO' THEN -valor ELSE 0 END) AS saldo_liquido, (SELECT t2.canal FROM transacoes t2 WHERE t2.cpf_cliente = t.cpf_cliente AND t2.status = 'EFETIVADA' GROUP BY t2.canal ORDER BY COUNT(*) DESC LIMIT 1) AS canal_mais_frequente, MAX(data_transacao) AS data_ultima_transacao FROM transacoes t WHERE status = 'EFETIVADA' GROUP BY cpf_cliente ORDER BY valor_total_credito DESC
```

Ponto-chave: CASE WHEN dentro do SUM faz agregação condicional sem precisar de JOIN. Saldo líquido = crédito soma positivo, débito soma negativo. Canal mais frequente via subquery é compatível com qualquer banco (MySQL, PostgreSQL, SQL Server).

BLOCO 3 — PYTHON

QUESTÃO 13 — Função limpar_base(df)

Implemente a função limpar_base(df) que receba um DataFrame com colunas: cpf, nome, data_nascimento, renda_mensal, uf, email. Regras: remover duplicatas por CPF (manter mais recente), filtrar idades entre 18 e 120 anos, tratar outliers de renda, retornar DataFrame com flag_revisao.

Nível Júnior — Python puro, etapas separadas:

```
from datetime import date def limpar_base(lista): # Etapa 1: remover duplicatas por CPF (ultimo sobrescreve) vistos = {} for registro in lista: vistos[registro['cpf']] = registro sem_duplicatas = list(vistos.values()) # Etapa 2: filtrar idades entre 18 e 120 anos hoje = date.today() resultado = [] for registro in sem_duplicatas: nascimento = registro['data_nascimento'] idade = (hoje - nascimento).days // 365 if 18 <= idade <=
```

```
120: resultado.append(registro) return resultado
```

Nível Pleno — pandas com IQR e flag_revisao:

```
import pandas as pd from datetime import date def limpar_base(df): df = df.copy() # 1.
Duplicatas por CPF: manter o mais recente (ultimo indice) df =
df.sort_index(ascending=False) df = df.drop_duplicates(subset='cpf', keep='first') # 2.
Filtrar idades plausíveis (18 a 120 anos) df['data_nascimento'] =
pd.to_datetime(df['data_nascimento'], errors='coerce') hoje = pd.Timestamp(date.today())
df['idade'] = (hoje - df['data_nascimento']).dt.days // 365 df =
df[df['idade'].between(18, 120)] # 3. Outliers de renda via IQR (adapta-se à distribuição
real) Q1 = df['renda_mensal'].quantile(0.25) Q3 = df['renda_mensal'].quantile(0.75)
limite_superior = Q3 + 1.5 * (Q3 - Q1) # 4. Flag revisao: renda zerada/negativa ou acima
do limite df['flag_revisao'] = (df['renda_mensal'] <= 0) | (df['renda_mensal'] >
limite_superior) df = df[df['renda_mensal'] > 0] return df.drop(columns=['idade'])
```

QUESTÃO 14 — Função analisar_inadimplencia(df)

Dataset com 100 mil contratos: valor_contrato, prazo_meses, renda_cliente, idade, uf, canal_contratacao, inadimplente (0/1). Taxa geral de inadimplência: 8%. Calcule taxa por faixa de renda (min. 4 faixas) e por canal. Retorne dicionário formatado para relatório.

Nível Pleno:

```
import pandas as pd def analisar_inadimplencia(df): df = df.copy() # Faixas de renda com
labels descritivos faixas = [0, 2000, 5000, 10000, float('inf')] rotulos = ['Ate
R$2.000', 'R$2.001 a R$5.000', 'R$5.001 a R$10.000', 'Acima de R$10.000'] df['faixa_renda']
= pd.cut(df['renda_cliente'], bins=faixas, labels=rotulos) # Taxa + volume por faixa de
renda por_faixa = df.groupby('faixa_renda')['inadimplente'].agg( taxa=lambda x:
round(x.mean() * 100, 2), total_contratos='count', total_inadimplentes='sum'
).reset_index() # Taxa + volume por canal por_canal =
df.groupby('canal_contratacao')['inadimplente'].agg( taxa=lambda x: round(x.mean() * 100,
2), total_contratos='count', total_inadimplentes='sum' ).reset_index() return {
'taxa_geral': round(df['inadimplente'].mean() * 100, 2), 'por_faixa_renda':
por_faixa.to_dict(orient='records'), 'por_canal': por_canal.to_dict(orient='records') }
```

Ponto-chave: incluir total_contratos junto com a taxa evita que o gestor tome decisão baseada em amostra pequena. IQR para outliers de renda é mais robusto que limites fixos pois se adapta à distribuição real dos dados.

BLOCO 4 — QUESTÕES DISCURSIVAS

QUESTÃO 15 — Canais de atendimento (app vs presencial)

A diretoria solicitou análise sobre performance de canais (presencial, app, web, teleatendimento) nos últimos 12 meses. Achados: app cresceu 40% em volume mas NPS 15 pontos abaixo do presencial; custo presencial 8x maior que app; faixa etária 60+ utiliza quase exclusivamente o canal presencial. 1) Como estruturaria a apresentação e quais visualizações usaria? 2) Que cuidados tomaria para não gerar decisão precipitada?

Resposta Nível Pleno:

Estruturaria a apresentação em quatro visualizações com narrativa progressiva. Começaria com um gráfico de linhas mostrando a evolução de volume por canal nos últimos 12 meses — contextualizando o crescimento do app. Na sequência, um gráfico de barras comparando o custo por atendimento entre canais, ancorando a discussão financeira: presencial custa 8x mais que o app. Depois, barras comparando NPS por canal, introduzindo a tensão: o app cresce e é mais barato, mas tem satisfação inferior. Por fim, distribuição de faixa etária por canal, explicando o porquê: o público 60+ concentra o uso

presencial e praticamente não avalia o app. Para evitar decisão precipitada, apresentaria três limitações: primeiro, volume não é receita — seria necessário cruzar canal com ticket médio antes de qualquer recomendação de fechamento. Segundo, o NPS baixo do app pode não refletir o canal em si, já que o público 60+ não o utiliza e portanto não o avalia. Terceiro, em contexto de banco público, fechamento de agências envolve obrigações regulatórias e risco de evasão de clientes de longa data.

QUESTÃO 16 — Queda de 15% na conversão de propostas de crédito

A gerência percebeu queda de 15% na conversão de propostas em contratos efetivados nos últimos 3 meses. Você tem acesso a: base de propostas (status, canal, produto, perfil do cliente), dados transacionais, histórico de campanhas e pesquisas de satisfação. 1) Quais hipóteses formularia e que análises faria? 2) Como estruturaria a devolutiva para o gestor?

Resposta Nível Pleno:

Formularia três hipóteses principais: mudança no perfil dos clientes que recebem proposta, problema operacional em alguma etapa do processo de efetivação, ou queda na qualidade de canal específico. Para testar, analisaria a base de propostas dos últimos 6 meses segmentada por canal, produto e perfil — com gráfico de linha para identificar quando e onde a queda começou. Em seguida, avaliaria o funil por etapa: onde as propostas estão sendo perdidas — na aprovação, documentação ou fechamento? Cruzaria com histórico de campanhas e pesquisa de satisfação para identificar fatores associados ao período da queda. Para a devolutiva, estruturaria em três partes: achados (onde e quando a queda ocorre), hipótese principal (baseada nos dados cruzados) e recomendações (ações concretas para o segmento identificado). Deixaria explícito o que ainda precisaria ser investigado para confirmar a causa raiz, evitando recomendações precipitadas antes de ter evidências suficientes.

RESUMO — O QUE O AVALIADOR OBSERVA

Critério	Júnior	Pleno
SQL	WHERE/GROUP BY/HAVING corretos	Window functions, subquery correlacionada
Python	Lógica correta, sintaxe básica	IQR, type hints, tratamento de borda
Estatística	Reconhece média vs mediana	Sabe quando usar teste não paramétrico
Negócio	Responde o que foi perguntado	Antecipa limitações e propõe próximos passos
Comunicação	Apresenta os dados	Traduz dado em decisão com narrativa

Dica final: a diferença entre jr e pleno muitas vezes não está no código — está na capacidade de antecipar perguntas do gestor, apresentar limitações dos dados e propor próximos passos sem ser direcionado.