

A prova técnica da ID Singular foi composta por 11 questões de múltipla escolha e 5 questões abertas, sendo que, destas últimas, 3 exigiam o desenvolvimento de códigos em SQL e Python e 2 de dissertação.

Na parte de **Power BI, em visualizações**, foram abordados temas como **truncamento de valores para 0 e 7**, locais onde é possível **configurar alertas** e identificação do **gráfico** mais adequado (**linhas**) para análise de tendências.

As questões destacavam que **alertas** funcionam apenas em visuais que exibem indicadores numéricos, como **Cartão, KPI e Medidor**. Também foi necessário diferenciar esses elementos: o Cartão apresenta um valor isolado, o KPI exibe valor, meta e tendência, enquanto o Medidor mostra o valor dentro de uma escala. Ao todo, foram 3 questões relacionadas ao **Power BI (Truncamento, Gráficos e Alertas)**.

Percebi ausência de temas relevantes em **Power BI** como **CALCULATE, ALL** e à diferença entre **Medidas e Colunas Calculadas**.

Em **Análise Exploratória de Dados (EDA)**, houve uma questão envolvendo a escolha entre **moda, mediana e média** para conjuntos de dados **com poucos valores muito altos e distribuição com cauda positiva**. O enunciado era relativamente confuso, mas buscava avaliar qual medida seria mais adequada para geração de **insights gerenciais** e também aplicável a **dados categóricos**.

Outra questão tratava da diferença entre **correlação e causalidade**, sendo igualmente ambígua, maioria tinha a palavra causalidade nas alternativas; a interpretação mais provável apontava para uma correlação superior a 0,90 como indicativo de forte associação para descrever os dados com maior confiança.

Houve ainda uma questão envolvendo as funções `scipy.stats.describe`, `describe()` e `summary()` (R), além de `info()`, com foco na **identificação de padrões, outliers e geração de insights**. Esse bloco totalizou 3 questões. EDA (Medidas de Tendência Central, Estatística Assimétrica e Simétrica, Correlação e Resumo Estatístico)

Em **Governança e Qualidade de Dados**, foi apresentada uma questão considerada bastante confusa, abordando a necessidade de aplicação desses conceitos de forma **obrigatória em todas as etapas do pipeline de dados**. Os tópicos centrais envolviam linhagem dos dados, auditoria, logs, relatórios e documentação técnica.

Uma questão sobre **coleta e tratamento de dados**, considerada simples em comparação com os demais tópicos da avaliação.

Por fim, a parte de **negócios** contou com 3 questões consideradas tranquilas e de fácil interpretação, voltadas para raciocínio analítico e contexto empresarial. Totalizando 11 questões.

DISSERTAÇÃO (INDICADORES)

PERGUNTA:

Questão pediu como apresentaria para diretoria executiva e quais gráficos usaria e justificar na sequência e como falar para diretoria sem falar em fechar agências. Desafio: uma coluna que contem tipos de canais. APP 40% de volume maior na digital, mas NPS da digital 15 pontos menor que o presencial. Usuários 60+ usam quase exclusivamente presencial, CUSTO em agências presencial 8X maior. Atenção, pedi também quais cruzamentos podem serem feitos.

RESPOSTA:

Para a diretoria executiva precisa apresentar de forma estratégica e clara. Primeiro mostrar que o **APP concentra 40% do volume digital**, mas que o **NPS digital é 15 pontos inferior ao presencial**, o que sinaliza uma oportunidade de melhoria na experiência online.

Em seguida, destaca que os **usuários 60+ utilizam quase exclusivamente o canal presencial**, reforçando a sua relevância, principalmente na experiência do usuário. Outro dado crítico é que o **custo das agências presenciais é 8 vezes maior**, o que torna essencial equilibrar eficiência e qualidade. Para tornar a mensagem visualmente impactante, utiliza-se **gráficos de barras** para comparar volumes por canal, **gráficos de linha** para mostrar tendências de NPS ao longo do tempo e **segmentações por faixa etária**, que evidenciam o perfil dos usuários.

A justificativa é que esses visuais são simples, objetivos e permitem à diretoria compreender os pontos fortes e fracos sem falar em fechamento de agências, mas sim em oportunidades de evolução para geração de novos negócios e melhoria da experiência do cliente. Por fim, sugere-se **cruzamentos** como **canal x NPS**, **canal x faixa etária** e **canal x volume**, que ajudam a identificar onde investir para equilibrar a jornada entre digital e presencial.

DISSERTAÇÃO

PERGUNTA:

“As vendas caíram 18% no trimestre. Como investigaria? ” Como trataria conflitos de divergência de prioridades entre áreas e que fosse de urgência?

RESPOSTA:

Versão 1

Diante de uma queda de 18% nas vendas no trimestre, a primeira etapa seria **investigar as causas com dados objetivos**: analisar tendências históricas, comparar desempenho por produto, canal e região, verificar sazonalidade e cruzar com indicadores externos (concorrência, economia, comportamento do consumidor). Também seria essencial avaliar métricas de satisfação (NPS, reclamações, churn) e eficiência operacional (estoque, logística, atendimento).

Quanto aos **conflitos de prioridades entre áreas**, especialmente em situações de urgência, a abordagem mais eficaz é criar um **comitê de crise multidisciplinar** com representantes de cada área, alinhando objetivos comuns e estabelecendo critérios claros de decisão (impacto financeiro, risco reputacional, tempo de resposta). A comunicação deve ser **transparente, com matriz de priorização e orientada a dados**, mostrando à diretoria executiva cenários possíveis e alternativas de ação.

Assim, a investigação se torna estruturada:

- **Diagnóstico rápido** com dashboards comparativos.
- **Cruzamentos estratégicos**: canal x vendas, produto x margem, região x NPS.
- **Priorização conjunta**: decidir onde agir primeiro com base em impacto e urgência.
- **Narrativa para diretoria**: não apenas apontar problemas, mas propor soluções práticas, como reforço em canais digitais, campanhas direcionadas ou ajustes operacionais, **sem sugerir cortes imediatos**.

Versão 2

Primeiramente, eu buscaria entender o contexto da queda e validar a confiabilidade dos dados para garantir que não houve problema de integração ou contabilização.

Depois, segmentaria a análise por período, região, produto, canal de vendas e perfil de clientes para identificar onde ocorreu o maior impacto.

Em seguida, compararia os indicadores com trimestres anteriores e avaliaria métricas relacionadas, como volume de vendas, ticket médio, taxa de conversão e cancelamentos. Também investigaria fatores externos e internos, como mudanças de preço, campanhas, sazonalidade, estoque ou alterações operacionais.

Após identificar a possível causa raiz, apresentaria os principais insights e sugeriria ações priorizadas para recuperação dos resultados.

PYTHON. A função **limpar_dados** foi criada para organizar o dataframe de forma prática: primeiro remove outliers usando a técnica IQR, por ser simples e robusta; depois trata valores nulos substituindo pela mediana e elimina duplicados; por fim, adiciona uma nova coluna booleana que indica TRUE ou FALSE conforme o valor esteja acima ou abaixo da mediana.

```
import pandas as pd

def limpar_dados(df):
    # Outliers com IQR: técnica simples e robusta contra extremos
    Q1, Q3 = df['valor_liquido'].quantile([0.25, 0.75])
    IQR = Q3 - Q1
    df = df[(df['valor_liquido'] >= Q1-1.5*IQR) & (df['valor_liquido'] <= Q3+1.5*IQR)]

    # Identifica e substitui os nulos pela mediana das colunas numéricas
    df = df.fillna(df.median(numeric_only=True))

    # Duplicados
    df = df.drop_duplicates()

    # Nova coluna TRUE/FALSE com base na mediana atualizada
    mediana = df['valor_liquido'].median()
    df['acima_mediana'] = df['valor_liquido'] > mediana

    return df
```

Observação: A questão não solicitou padroniza textos, retirar espaços extras, corrigir escritas e colocar tudo em minúsculas

PYTHON. Foi criada uma função que recebe um dataframe já estruturado com pelo menos cinco colunas, adiciona uma nova coluna que classifica os valores em quatro faixas distintas e, em seguida, percorre o dataframe com um loop for, exibindo de forma organizada a chave e o valor de cada linha, garantindo simplicidade e clareza no processo de manipulação dos dados.

```
import pandas as pd

def processar_faixas(df):
    # Cria a coluna com 4 faixas de valores (quebrado para caber na tela)
    faixas = ['Baixo', 'Médio', 'Alto', 'Muito Alto']
    df['faixa_valor'] = pd.cut(df['valor_liquido'], bins=4, labels=faixas)

    # Loop FOR percorrendo a coluna com chave (índice) e valor
    for chave, valor in df['faixa_valor'].items():
        print(f"Índice {chave} -> Faixa: {valor}")

    return df
```

```
import pandas as pd

def processar_faixas(df):
    # Cria a coluna com 4 faixas de valores
    faixas = ['Baixo', 'Médio', 'Alto', 'Muito Alto']
    df['faixa_valor'] = pd.cut(df['valor_liquido'], bins=4, labels=faixas)

    # Loop FOR direto apenas pelos valores da coluna
    for valor in df['faixa_valor']:
        print(f"Faixa: {valor}")

    return df
```

SQL. A query deve retornar cada cliente linha a linha, somar os valores líquidos e ordenar em ordem decrescente, calcular a média dos valores com arredondamento em duas casas decimais, contar os tipos únicos de contas de débito, separar crédito e débito, verificar a data atual e aplicar um filtro para mostrar apenas clientes inadimplentes.

```
SELECT
    t.cliente_id,
    t.nome,
    SUM(t.valor_liquido) AS total_liquido,
    ROUND(AVG(t.valor_liquido), 2) AS media_valores,
    COUNT(DISTINCT CASE WHEN t.tipo_conta = 'debito'
        THEN t.tipo_conta END) AS contas_debito_unicas,
    SUM(CASE WHEN t.tipo_conta = 'credito'
        THEN t.valor_liquido ELSE 0 END) AS total_credito,
    SUM(CASE WHEN t.tipo_conta = 'debito'
        THEN t.valor_liquido ELSE 0 END) AS total_debito,
    CURRENT_DATE AS data_atual
FROM transação t
WHERE t.situacao = 'inadimplente'
GROUP BY t.cliente_id, t.nome
ORDER BY total_liquido DESC;
```

A cláusula GROUP BY t.cliente_id, t.nome, o banco de dados vai agrupar todas as transações de um mesmo cliente e mostrar **um único registro (uma linha) por cliente**, consolidando os valores dele (somadas, médias e contagens).

ID	Nome	Total Liq.	Média
1042	Carlos Silva	5450.00	1816.67
1015	Mariana Costa	3200.50	1600.25
1089	Roberto Souza	2100.00	700.00
1023	Juliana Lima	1850.00	1850.00
1001	Ana Rodrigues	950.00	475.00

Déb. Único	Tot. Créd.	Tot. Déb.	Data
1	3500.00	1950.00	13/06/2026
1	0.00	3200.50	13/06/2026
1	1500.00	600.00	13/06/2026
0	1850.00	0.00	13/06/2026
1	450.00	500.00	13/06/2026